

Monitoreo satelital de cianobacterias en los lagos de Atitlán y Amatitlán

Laboratorio 4 – CC3084 Data Science – Sección 20 – Grupo #7
Marco Carbajal (23025) Carlos Angel (23010) Diego Monroy (23318)

1 Qué se midió y cómo

Las cianobacterias son microorganismos que, cuando el agua tiene exceso de nutrientes, temperatura alta y poco movimiento, se multiplican hasta formar floraciones que pueden ser tóxicas. Medirlas con muestreos en campo es caro y solo describe el punto donde se tomó la muestra, así que en este trabajo se usó observación satelital, que cubre el lago completo y permite comparar fechas distintas con el mismo criterio.

- **Datos:** 22 imágenes del satélite Sentinel-2 del programa Copernicus, 11 fechas por lago, entre enero de 2025 y julio de 2026. Son las fechas oficiales del laboratorio, todas con nubosidad baja.
- **Índice de cianobacteria (NDCI):** compara la luz que el agua refleja en el borde rojo y en el rojo, dos colores en los que la clorofila de las cianobacterias deja una huella clara. Se calculó con el script público de cianobacterias de Sentinel Hub, que además convierte el índice a clorofila-a en microgramos por litro, la unidad que se usa en calidad de agua.
- **Índices de apoyo:** el NDWI separa el agua de la tierra y sirve para medir solo dentro del lago, y el NDVI describe la vegetación del entorno.
- **Resolución:** cada dato corresponde a un cuadro de 10 por 10 metros de superficie, es decir 100 metros cuadrados.
- **Umbral de floración:** se considera floración visible un NDCI mayor a 0.2, valor a partir del cual el agua ya presenta una carga alta de material fotosintético en suspensión.




Figura 1: Los tres índices en el lago de Amatitlán el 29 de marzo de 2026. El NDVI (izquierda) muestra la vegetación del entorno, el NDWI (centro) delimita el espejo de agua y el mapa de cianobacteria (derecha) se calcula únicamente dentro de esa agua. El rojo indica concentraciones altas.

2 Estado general de los dos lagos

Los dos lagos están en situaciones opuestas, y la diferencia no es de matiz sino de un orden de magnitud.

Lago	NDCI promedio	NDCI máximo	Clorofila-a media (ug/L)	Clorofila-a máxima (ug/L)	Fechas con floración	Superficie afectada
Atitlán	−0.026	0.014	3.5	4.3	0 de 11	5%
Amatitlán	0.217	0.397	12.5	54.2	5 de 11	55%

Cuadro 1: Resumen de las 11 fechas de cada lago. La superficie afectada es el porcentaje promedio del espejo de agua que supera el umbral de floración.

Amatitlán presenta valores propios de un lago hipereutrófico, es decir con exceso permanente de nutrientes: su clorofila-a promedio de 12.5 microgramos por litro triplica a la de Atitlán y en la peor fecha llega a 54.2. Atitlán

se mantiene entre 3 y 4 microgramos por litro en todas las fechas, un nivel de agua limpia, y ninguna de sus imágenes alcanza el umbral de floración.

3 Cómo cambió en el tiempo




Figura 2: Evolución del índice de cianobacteria en cada lago. La línea punteada es el promedio del periodo. Las escalas verticales son distintas: el rango completo de Atitlán cabe dentro de las fluctuaciones de Amatitlán.

En Amatitlán la serie fluctúa mucho, pero siempre en niveles altos: baja hasta 0.12 en abril de 2025 y febrero de 2026, y sube a 0.27 en enero y abril de 2026. El pico del periodo es el 19 de junio de 2026, con un índice de 0.397 y 54.2 microgramos por litro de clorofila-a, la única fecha que supera el criterio de floración excepcional, definido como el promedio del lago más una desviación estándar. Es también la única fecha del periodo que cae en época lluviosa, cuando la escorrentía arrastra nutrientes y el agua está más caliente. Con una sola observación de esa temporada no se puede afirmar un patrón estacional, pero la dirección coincide con lo esperado. Vale la pena señalar que el promedio de las fechas de 2026, de 0.24, es mayor que el de 2025, de 0.18.

En Atitlán la serie se mantiene plana alrededor de cero durante los dos años, sin ningún pico. Sus valores más altos, que aun así son bajos, caen en julio de 2025, abril de 2026 y julio de 2026.

Lago de Atitlán				Lago de Amatitlán			
Fecha	NDCI	Clorofila (ug/L)	Superficie afectada	Fecha	NDCI	Clorofila (ug/L)	Superficie afectada
2025-01-18	−0.139	0.0	24.2%	2025-01-28	0.248	11.7	76.0%
2025-04-13	−0.030	3.4	0.6%	2025-04-15	0.129	5.0	28.7%
2025-05-13	−0.009	4.0	0.5%	2025-04-28	0.171	5.4	42.7%
2025-07-17	0.014	4.3	1.7%	2025-11-24	0.181	6.3	37.9%
2025-11-21	−0.018	4.1	12.9%	2026-01-08	0.271	14.2	81.1%
2025-12-29	−0.059	3.1	4.4%	2026-02-02	0.122	5.3	14.6%
2026-02-12	−0.024	3.7	6.0%	2026-02-07	0.180	6.9	41.0%
2026-03-24	−0.010	3.9	0.7%	2026-03-29	0.228	9.6	68.0%
2026-04-13	0.006	4.3	0.7%	2026-04-13	0.267	13.6	88.4%
2026-04-28	−0.020	3.7	0.5%	2026-04-28	0.195	5.2	41.1%
2026-07-22	0.007	4.2	1.0%	2026-06-19	0.397	54.2	87.0%

Cuadro 2: Resultados fecha por fecha. La imagen de Atitlán del 18 de enero de 2025 no es comparable con el resto por las razones que se explican en la sección de limitaciones.

4 Dónde se concentra la floración dentro del lago

El promedio de un lago esconde lo más útil para el manejo, que es saber dónde ocurre el problema. Al superponer las 11 fechas de Amatitlán aparece un patrón muy estable.




Figura 3: Porcentaje de las 11 fechas en que cada punto del lago de Amatitlán superó el umbral de floración. La cuenca norte, donde desemboca el río Villalobos, aparece en amarillo y naranja; la cuenca sur, del lado de la salida hacia el río Michatoya, se mantiene más limpia.

Sobre los 14.3 kilómetros cuadrados de agua permanente del lago, la mitad norte promedia un índice de 0.264 y la mitad sur 0.192. El diez por ciento de los puntos con mayor carga promedia 0.323 y se ubica en la cuenca norponiente, justo donde entra el río Villalobos con el drenaje del área metropolitana. Esa mitad norte supera el umbral en cerca del 71 por ciento de las fechas, contra el 44 por ciento de la mitad sur. No se trata de un episodio aislado sino de una zona de acumulación permanente, y es el sitio donde tendría más sentido concentrar el muestreo en campo y las alertas al público.




Figura 4: Las 11 fechas del lago de Amatitlán en la misma escala de color. Lo que cambia entre fechas es la intensidad, no la ubicación: la cuenca norte siempre aparece más cargada que la sur.

En Atitlán no existe ningún patrón equivalente. El promedio de las 11 fechas es plano en todo el espejo de agua y los puntos más altos y más bajos se ubican prácticamente en el mismo lugar, lo que indica ruido de medición y no una estructura real. Los únicos valores que superan el umbral forman una franja delgada pegada a la orilla,

donde el cuadro de 10 metros mezcla agua con vegetación ribereña y por eso el índice sube de forma artificial.

5 Cuánta superficie cubren las floraciones




Figura 5: Porcentaje del espejo de agua con floración en cada fecha. En Amatitlán, seis de las once fechas superan el 40 por ciento del lago. Las escalas verticales son distintas.

En Amatitlán la extensión va del 15 por ciento en febrero de 2026 al 88 por ciento en abril de 2026, y en seis de las once fechas más del 40 por ciento del lago está afectado. La floración de junio de 2026 no es una mancha local: cubre prácticamente todo el espejo de agua, y el aumento respecto a febrero es positivo en toda la superficie.

En Atitlán los valores parecen altos en cuatro fechas, con 24.2 por ciento en enero de 2025 y 12.9 por ciento en noviembre de 2025, pero esas cuatro fechas son exactamente las cuatro imágenes con menos píxeles útiles por bruma y sombra. Son artefactos de la imagen y no floraciones reales, y conviene tenerlo presente porque es el tipo de dato que puede llevar a una alerta equivocada.

6 Comparación entre los dos lagos




Figura 6: Distribución del índice en las 11 fechas de cada lago. Las dos distribuciones no se traslapan y solo Amatitlán cruza el umbral de floración.

- **Intensidad:** Amatitlán promedia 0.217 y llega a 0.397, contra un promedio de -0.026 y un máximo de 0.014 en Atitlán. En clorofila-a la diferencia es de 12.5 frente a 3.5 microgramos por litro en promedio.
- **Frecuencia:** 5 de las 11 fechas de Amatitlán superan el umbral y ninguna de Atitlán lo hace. En Amatitlán la floración no es un evento, es un estado permanente que solo cambia de intensidad.
- **Extensión:** 55 por ciento del lago afectado en promedio en Amatitlán, contra 5 por ciento en Atitlán, y ese 5 por ciento corresponde a la orilla y a las fechas con bruma.

7 Qué explica la diferencia

Las causas apuntan a la presión urbana y a la forma misma de cada lago.

- **Carga de nutrientes:** Amatitlán recibe por el río Villalobos el drenaje de la cuenca metropolitana, con aguas residuales en su mayoría sin tratamiento, descargas industriales y escorrentía de suelo urbanizado y agrícola. Ese aporte entra por la orilla norte, que es precisamente la de mayor carga en los mapas.
- **Volumen y profundidad:** Amatitlán tiene unos 15 kilómetros cuadrados y poca profundidad, mientras que Atitlán supera los 100 kilómetros cuadrados y varios cientos de metros de profundidad, de modo que el mismo aporte de nutrientes se diluye en un volumen mucho mayor.
- **Temperatura y altitud:** Amatitlán está a menor altitud y su agua es más cálida, condición que favorece el crecimiento de las cianobacterias durante todo el año.
- **Uso del suelo:** la cuenca de Atitlán es menos poblada y conserva más bosque y cultivo de café, con una presión sobre el agua mucho menor que la del corredor urbano que drena hacia Amatitlán.

8 Modelos de clasificación

La unidad de modelado es un píxel válido de agua de 10 por 10 metros. La variable respuesta toma el valor 1 cuando la clorofila-a estimada es al menos 12 microgramos por litro, entrada al Nivel de Alerta 1, y 0 en caso contrario. El conjunto contiene 450,499 observaciones de 21 fechas; la imagen de Atitlán del 18 de enero de 2025 se excluyó porque solo conservó 2.98% de cobertura válida. La clase positiva representa 6.15%, por lo que la exactitud por sí sola no es un criterio suficiente.

Se utilizaron B03, B04, B08, NDVI, NDWI, los cocientes verde/rojo y NIR/verde, brillo, textura local del NDWI y distancia a la orilla. Se excluyeron clorofila-a, NDCI y B05: las dos primeras definen directamente la respuesta y B05, junto con B04, permite reconstruir NDCI. También se excluyeron lago, fecha, latitud y longitud para evitar que los modelos memorizaran la ubicación en vez de aprender la firma espectral.

8.1 Entrenamiento y comparación justa

Se hizo una única división estratificada y reproducible: 70% para entrenamiento y 30% para prueba, con semilla 42. Los tres algoritmos —Regresión Logística, Random Forest y Gradient Boosting por histogramas— recibieron exactamente los mismos índices de prueba. Primero se entrenaron con su configuración inicial y umbral 0.5. Después, el ajuste de hiperparámetros se realizó exclusivamente dentro del 70% de entrenamiento mediante validación estratificada de tres particiones. El conjunto de prueba no intervino ni en la selección de parámetros ni en la elección del umbral.

Debido al tamaño del conjunto, la búsqueda se realizó sobre una submuestra estratificada de 120,000 observaciones del entrenamiento y la configuración elegida se volvió a ajustar con todo el 70%. Los valores evaluados fueron:

- **Regresión Logística:** $C \in \{0.01, 0.1, 1, 10\}$ y pesos de clase nulos o balanceados. Las variables se estandarizaron dentro de un *pipeline* para que la escala se aprendiera sin observar la prueba.
- **Random Forest:** 250 árboles; profundidad máxima de 12, 24 o sin límite; mínimo de 1, 5 o 20 observaciones por hoja; número de variables por división igual a la raíz del total o 70%; y pesos nulos o balanceados por submuestra. Se evaluaron diez combinaciones aleatorias con semilla fija.
- **Gradient Boosting:** tasa de aprendizaje de 0.03, 0.07 o 0.12; 100 o 200 iteraciones; 15, 31 o 63 hojas; mínimo de 20 o 100 observaciones por hoja; regularización L2 de 0 o 1; y pesos de clase nulos o balanceados. Se evaluaron diez combinaciones aleatorias con semilla fija.

El criterio de selección fue F2, que da al *recall* el doble de importancia que a la precisión. Luego se reservó 15% del entrenamiento como validación interna para elegir, entre 0.05 y 0.95, el umbral que maximizó F2; por último cada modelo se reentrenó con todo el entrenamiento antes de evaluarlo una sola vez en la prueba.

8.2 Criterio ambiental de evaluación

Un falso positivo marca como alta presencia una zona que no la tiene. Esto puede producir una alerta innecesaria, muestreos adicionales, gasto operativo y pérdida de confianza si se repite. Un falso negativo omite una zona que sí tiene alta presencia, lo cual puede retrasar el muestreo confirmatorio y mantener la exposición recreativa o el uso del agua ante una floración potencialmente tóxica. Para un sistema de alerta temprana se considera más

importante reducir falsos negativos. Por ello la comparación principal usa F2 y *recall*; ROC-AUC se reporta como medida general de discriminación, pero no representa por sí sola el costo desigual de los dos errores.

8.3 Resultados iniciales

Con umbral 0.5 y antes del ajuste, Random Forest presentó el mayor F2 y F1. La exactitud de los tres modelos fue alta, pero debe interpretarse junto con el *recall*: por el desbalance, un modelo puede acertar la mayoría de los negativos y aun así omitir muchas zonas afectadas.

Modelo	Accuracy	Precision	Recall	F1	F2	ROC-AUC
Regresión Logística	0.954	0.741	0.396	0.516	0.436	0.884
Random Forest	0.971	0.843	0.657	0.738	0.687	0.979
Gradient Boosting	0.970	0.843	0.632	0.722	0.665	0.981

Cuadro 3: Desempeño inicial sobre las mismas 135,150 observaciones de prueba, usando umbral 0.5.

8.4 Configuraciones seleccionadas

La búsqueda eligió $C = 10$ y pesos balanceados para Regresión Logística. Para Random Forest seleccionó profundidad 24, mínimo de 20 observaciones por hoja, 70% de variables por división y pesos balanceados por submuestra. Para Gradient Boosting eligió tasa 0.03, 200 iteraciones, 63 hojas, mínimo de 20 observaciones por hoja, regularización L2 igual a 0 y pesos balanceados. Los F2 medios de validación cruzada fueron 0.582, 0.773 y 0.764, respectivamente. Los umbrales seleccionados en la validación interna fueron 0.600, 0.595 y 0.725.

8.5 Resultados finales

Modelo	Accuracy	Precision	Recall	F1	F2	ROC-AUC
Regresión Logística	0.912	0.381	0.701	0.493	0.600	0.913
Random Forest	0.954	0.588	0.870	0.702	0.794	0.982
Gradient Boosting	0.950	0.558	0.880	0.683	0.789	0.982

Cuadro 4: Desempeño final sobre el conjunto común de prueba después del ajuste.




Figura 7: Comparación de las métricas finales. Random Forest y Gradient Boosting superan claramente a la Regresión Logística en *recall*, F1, F2 y ROC-AUC.

Modelo	Umbral	TN	FP	FN	TP
Regresión Logística	0.600	117,368	9,467	2,490	5,825
Random Forest	0.595	121,763	5,072	1,079	7,236
Gradient Boosting	0.725	121,046	5,789	994	7,321

Cuadro 5: Matrices de confusión finales expresadas como conteos: verdaderos negativos (TN), falsos positivos (FP), falsos negativos (FN) y verdaderos positivos (TP).




Figura 8: Matrices de confusión de los modelos ajustados sobre las mismas 135,150 observaciones de prueba.

Random Forest es el modelo final recomendado: alcanza el mayor F2 (0.794), el mayor ROC-AUC (0.9824) y mantiene un *recall* de 0.870 con menos falsos positivos que Gradient Boosting. Gradient Boosting detecta 85 positivos adicionales y reduce los falsos negativos de 1,079 a 994, pero genera 717 falsos positivos más; su F2 queda ligeramente por debajo, en 0.789. Si la política operativa exigiera minimizar los falsos negativos casi sin importar el costo de inspección, Gradient Boosting sería defendible por su *recall* de 0.880. Bajo el balance ambiental adoptado mediante F2, Random Forest ofrece la mejor relación entre detección y falsas alarmas.